Package 'bibliolab'

October 16, 2026

Type Package

Title Guided Bibliometric Analysis and Text Mining

Version 5.0.1

Date 2026-10-16

Description A guided 'shiny' application, together with a set of functions, to describe a bibliographic corpus (production, sources, authors, citations, references) and to explore its text with exploratory models: latent Dirichlet allocation, correspondence analysis, principal component analysis, UMAP with HDBSCAN, Jensen-Shannon divergence and co-occurrence networks. Decisions that change the results (number of topics, stability of clusters, sampling noise of divergences, chance baselines for axes) are assisted and recorded, and the analysis can be exported as a reproducible bundle with a methodological report, parameters, seeds and a replication script. It is designed for researchers without technical training, and all computation is local.

License MIT + file LICENSE

Language es

Encoding UTF-8

URL https://github.com/majesus/bibliolab

BugReports https://github.com/majesus/bibliolab/issues

Depends R (>= 4.1.0)

Imports DT,
data.table,
ggplot2,
grDevices,
grid,
htmltools,
jsonlite,
Matrix,
methods,
parallel,
plotly,
shiny,
stats,
stopwords,
tools,

utils,
visNetwork,
zip

Suggests cld2,
dbscan,
ggrepel,
igraph,
irlba,
knitr,
mclust,
mgcv,
pkgload,
readxl,
rmarkdown,
slam,
testthat (>= 3.0.0),
topicmodels,
udpipe,
uwot,
withr

Config/bibliolab/App-Suggests cld2, dbscan, ggrepel, igraph, irlba, mclust, mgcv, readxl, slam, topicmodels, udpipe, uwot

Config/testthat/edition 3

Roxygen list(markdown = TRUE)

VignetteBuilder knitr

RoxygenNote 7.3.1

Contents

biblio_check_dependencies . . . 3
biblio_summary . . . 3
default_config . . . 4
density_sensitivity . . . 4
download_language_model . . . 5
export_bundle . . . 6
extract_subgraph . . . 7
guess_columns . . . 7
jsd_shift . . . 8
jsd_uncertainty . . . 8
lda_select_k . . . 9
methods_report . . . 10
methods_report_html . . . 11
model_directory . . . 12
prepare_corpus . . . 12
prepare_documents . . . 13
read_biblio_csv . . . 14
read_biblio_file . . . 14
reproducibility_record . . . 15
run_app . . . 16
run_ca . . . 17

run_comparison 18
run_density 18
run_lda 19
run_network 20
run_pca 21
vocabulary_diagnostics 22

Index **24**

`biblio_check_dependencies` *Comprueba que paquetes opcionales estan disponibles*

Description

Algunas funciones dependen de paquetes en `Suggests`. Esta funcion indica cuales estan instalados y que parte de bibliolab queda deshabilitada si faltan. No instala nada: la instalacion es decision del usuario.

Usage

```
biblio_check_dependencies()
```

Value

`data.frame` con `paquete`, `instalado`, `habilita` e `instruccion`.

Examples

```
biblio_check_dependencies()
```

`biblio_summary` *Indicadores bibliometricos descriptivos*

Description

Produccion anual, fuentes, autores y palabras clave (con unificacion de variantes de escritura si `normalize_labels` esta activo), citas e indice h del corpus observado, y tablas de cobertura y referencias.

Usage

```
biblio_summary(prepared)
```

Arguments

`prepared`	Resultado de `prepare_documents()`.

Value

Lista con `overview`, `annual`, `sources`, `authors`, `keywords`, `cited`, `extensiones` y `normalizacion`.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
biblio_summary(prepare_documents(d, guess_columns(d)))$overview
```

`default_config` *Configuracion por defecto de la preparacion*

Description

Configuracion por defecto de la preparacion

Usage

```
default_config()
```

Value

Lista con los parametros de limpieza, filtrado y vocabulario usados por `prepare_documents()` y `prepare_corpus()`.

Examples

```
names(default_config())
```

`density_sensitivity` *Evaluar la estabilidad de UMAP + HDBSCAN*

Description

Repite el flujo con otras semillas (estabilidad) y con vecinos y `minPts` alrededor de los valores elegidos (sensibilidad), y compara cada agrupacion con la de referencia mediante el indice de Rand ajustado (ARI). Tambien resume, por grupo de referencia, su persistencia (Jaccard maximo) en las repeticiones. Un solo mapa no demuestra que los grupos sean reproducibles.

Usage

```
density_sensitivity(
  corpus,
  prepared,
  params = list(),
  seeds = NULL,
  neighbors = NULL,
  min_pts = NULL,
  vectors = NULL,
  embedding_model = "",
  progress = NULL
)
```

Arguments

corpus, prepared	Resultados de prepare_corpus() y prepare_documents().
params	Parametros de run_density() (ver density_defaults() interno).
seeds	Semillas adicionales; por defecto semilla + 1:4.
neighbors, min_pts	Valores alternativos; por defecto la mitad, el valor y el doble.
vectors, embedding_model	Vectores importados, si la representacion es "vectors".
progress	Funcion opcional function(i, total).

Value

Lista con reference, runs, summary, cluster_stability y params.

References

Hubert, L., Arabie, P. (1985). Comparing partitions. Journal of Classification. Hennig, C. (2007). Cluster-wise assessment of cluster stability. CSDA.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d))
cp <- prepare_corpus(p)
if (all(c("uwot", "dbscan", "irlba") %in% rownames(utils::installed.packages()))) {
  s <- density_sensitivity(cp, p, list(neighbors = 5L, min_pts = 3L), seeds = 1:2,
                           neighbors = 5L, min_pts = 3L)
  s$summary
}
```

---

download_language_model

Descarga y verifica un modelo UDPipe

Description

Solo debe invocarse por decision del usuario (requiere conexion). Guarda el modelo en model_directory() y comprueba que se puede cargar.

Usage

```
download_language_model(language, directory = model_directory())
```

Arguments

language	Codigo es, en, fr, de, it o pt.
directory	Carpeta de destino.

Value

Ruta del archivo del modelo.

`export_bundle` *Exporta una entrega reproducible*

Description

Escribe tablas CSV, parametros, informe HTML, informe metodologico, registro de reproducibilidad, guion `reproducir_analisis.R` y, si se proporcionan, los resultados de cada modelo.

Usage

```
export_bundle(
  directory,
  prepared,
  corpus,
  bibliography,
  lda = NULL,
  ca = NULL,
  prompt = NULL,
  density = NULL,
  raw = NULL,
  module_dir = NULL,
  network = NULL,
  comparison = NULL,
  pca = NULL,
  subgraph = NULL,
  reader = NULL,
  record = NULL,
  lda_selection = NULL,
  density_sens = NULL
)
```

Arguments

`directory`	Carpeta de destino (se crea si no existe).
`prepared`, `corpus`, `bibliography`	Resultados de la preparacion.
`lda`, `ca`, `density`, `network`, `comparison`, `pca`, `subgraph`	Resultados opcionales.
`prompt`	Texto de prompt a guardar (opcional).
`raw`	`data.frame` importado original; se guarda como RDS para reproducir.
`module_dir`	Ignorado (compatibilidad con V3).
`reader`	Cuaderno de lectura enlazada (opcional).
`record`	Registro de reproducibilidad; se calcula si es `NULL`.
`lda_selection`, `density_sens`	Resultados de `lda_select_k()` y `density_sensitivity()`.

Value

`directory`, de forma invisible.

extract_subgraph *Subgrafo inducido de una red*

Description

Subgrafo inducido de una red

Usage

```
extract_subgraph(
  parent,
  method = "ego",
  focus = "",
  order = 1L,
  selection = character()
)
```

Arguments

parent	Resultado de run_network().
method	"ego", "community", "component" o "manual".
focus	Nodo de referencia (no necesario en "manual").
order	Distancia del vecindario (0-3) para "ego".
selection	Nodos elegidos para "manual".

Value

Lista como la de run_network(), con indicadores recalculados.

guess_columns *Propone que columna cumple cada papel bibliometrico*

Description

Reconoce encabezados habituales de Web of Science (etiquetas de dos letras y nombres largos), Scopus y exportaciones en espanol/ingles. En exportaciones etiquetadas de WoS, ID (Keywords Plus) no se toma como identificador. La propuesta debe revisarse: el investigador decide la correspondencia final.

Usage

```
guess_columns(d)
```

Arguments

d	data.frame importado.

Value

Lista con las columnas propuestas para `text`, `title`, `id`, `year`, `source`, `authors`, `citations`, `keywords`, `doi`, `language`, `references` y `translated` (`""` si no se reconoce).

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
guess_columns(d)$text
```

---

jsd_shift *Divergencia de Jensen-Shannon y aportacion de cada termino*

Description

Calcula la JSD en bits (base 2, mezcla 50/50, rango 0-1) entre dos distribuciones de frecuencias con vocabulario comun, y la descompone en la aportacion no negativa de cada termino (Lin, 1991; Gallagher et al., 2021). Es un estimador sin correccion: con pocos documentos o tokens es sesgado al alza; usa `jsd_uncertainty()` o `run_comparison()` para una referencia nula.

Usage

```
jsd_shift(a, b)
```

Arguments

a, b	Vectores numericos no negativos con nombres unicos.

Value

Lista con `jsd`, `distancia` (raiz de la JSD) y `terms`.

Examples

```
jsd_shift(c(a = 5, b = 3, c = 2), c(a = 1, b = 3, c = 6))$jsd
```

---

jsd_uncertainty *Incertidumbre de la JSD entre dos grupos de documentos*

Description

La JSD calculada con conteos finitos es un estimador sesgado al alza: dos muestras del mismo corpus ya presentan una JSD positiva que crece cuando hay pocos documentos o tokens. Esta funcion compara la JSD observada con una distribucion nula por permutacion de las etiquetas de grupo entre documentos, y estima un intervalo por remuestreo de documentos (bootstrap percentil).

Usage

```
jsd_uncertainty(weighted, in_a, in_b, B = 500L, seed = 2026L, conf = 0.95)
```

Arguments

weighted	Matriz documento x termino (conteos o pesos por documento).
in_a, in_b	Indices logicos o enteros de los documentos de A y de B.
B	Numero de permutaciones y remuestreos.
seed	Semilla.
conf	Nivel del intervalo (0.5-0.99).

Value

Lista con observed, null_mean, null_p95, excess (observada menos media nula), p_value (permutacion, con correccion +1), ci (bootstrap) y tamanos.

References

Lin, J. (1991). Divergence measures based on the Shannon entropy. IEEE Trans. Inf. Theory. Gallagher, R. et al. (2021). Generalized word shift graphs. EPJ Data Science.

Examples

```
set.seed(1)
W <- matrix(rpois(60 * 8, 2), 60, 8, dimnames = list(NULL, letters[1:8]))
jsd_uncertainty(W, 1:30, 31:60, B = 100, seed = 1)$p_value
```

---

lda_select_k *Comparar soluciones LDA con distinto numero de temas*

Description

Ajusta modelos LDA (Gibbs) para un rango de numeros de temas y varias semillas y resume, para cada k, indicadores complementarios: coherencia tematica, diversidad de palabras principales, estabilidad entre semillas y perplejidad sobre unidades reservadas. No existe un k universalmente optimo: la funcion devuelve los criterios por separado, senala los conflictos entre ellos y un valor de compromiso (maximin) solo como punto de partida.

Usage

```
lda_select_k(
  corpus,
  k_range = 2:8,
  seeds = c(2026L, 2027L, 2028L),
  iterations = 500L,
  alpha = NULL,
  delta = 0.1,
  holdout = 0.1,
  top_n = 10L,
  progress = NULL
)
```

Arguments

corpus	Resultado de prepare_corpus().
k_range	Enteros entre 2 y 12.
seeds	Semillas de las repeticiones (al menos una; recomendadas tres).
iterations	Iteraciones de Gibbs por ajuste (100-2000).
alpha	Prior de mezcla por documento: NULL usa 1/k en cada ajuste; un numero constante; o una funcion de k.
delta	Prior de palabras por tema.
holdout	Fraccion de unidades reservada para la perplejidad (0 la desactiva).
top_n	Palabras principales por tema usadas en coherencia, diversidad y estabilidad.
progress	Funcion opcional function(i, total) para informar del avance.

Value

Lista con table (resumen por k), runs (un ajuste por fila), recommendation (mejor k por criterio, compromiso y avisos) y params.

References

Mimno, D. et al. (2011). Optimizing semantic coherence in topic models. EMNLP. Greene, D., O'Callaghan, D., Cunningham, P. (2014). How many topics? Stability analysis for topic models. ECML PKDD. Chang, J. et al. (2009). Reading tea leaves: how humans interpret topic models. NIPS.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d))
cp <- prepare_corpus(p)
if (requireNamespace("topicmodels", quietly = TRUE)) {
  sel <- lda_select_k(cp, k_range = 2:4, seeds = c(1, 2), iterations = 200)
  sel$recommendation$summary
}
```

---

methods_report *Informe metodologico en Markdown*

Description

Genera un texto en espanol con los procedimientos aplicados, parametros, diagnosticos de validez ejecutados (y los que no se han ejecutado), limitaciones y registro de reproducibilidad. Es un borrador para la seccion de metodos: no sustituye el juicio del investigador ni valida interpretaciones sustantivas.

Usage

```
methods_report(
  prepared,
  corpus,
  bibliography,
  lda = NULL,
  ca = NULL,
  pca = NULL,
  density = NULL,
  network = NULL,
  comparison = NULL,
  record = NULL,
  lda_selection = NULL,
  density_sensitivity = NULL
)
```

Arguments

prepared, corpus, bibliography	Resultados de prepare_documents(), prepare_corpus() y biblio_summary().
lda, ca, pca, density, network, comparison	Resultados de los modelos, si existen.
record	Salida de reproducibility_record(); se calcula si es NULL.
lda_selection	Salida de lda_select_k() (opcional).
density_sensitivity	Salida de density_sensitivity() (opcional).

Value

Cadena de texto en Markdown.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d))
cp <- prepare_corpus(p)
cat(substr(methods_report(p, cp, biblio_summary(p)), 1, 400))
```

---

methods_report_html *Convierte el informe metodologico a HTML autonomo*

Description

Conversor minimo (titulos, listas, tablas, negrita/cursiva y parrafos) sin dependencias externas; el contenido se escapa para evitar HTML inyectado.

Usage

```
methods_report_html(md)
```

Arguments

md	Cadena Markdown de methods_report().

Value

Cadena HTML completa.

Examples

```
cat(methods_report_html("# Titulo\n\nTexto con **negrita**."))
```

---

model_directory *Carpeta de modelos UDPipe*

Description

Usa la opcion bibliolab.model_dir si esta definida; en otro caso, la carpeta de datos de usuario de R (tools::R_user_dir("bibliolab", "data")). El paquete nunca descarga modelos sin una accion explicita del usuario.

Usage

```
model_directory()
```

Value

Ruta (puede no existir todavia).

Examples

```
model_directory()
```

---

prepare_corpus *Segmenta, limpia y selecciona el vocabulario*

Description

Tokeniza el texto (puntuacion como frontera), aplica palabras vacias, lemas y categorias gramaticales si se solicitan, y construye la matriz unidad x termino con criterios de presencia, frecuencia, TF-IDF y entropia. Cada termino excluido conserva su motivo en terms.

Usage

```
prepare_corpus(prepared, progress = NULL)
```

Arguments

prepared	Resultado de prepare_documents().
progress	Funcion opcional function(stage, current, total).

Value

Lista con `units`, `counts`, `terms`, `ngrams`, `bigrams`, `issues`, `vocabulary`, `models` y `processing`.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
cp <- prepare_corpus(prepare_documents(d, guess_columns(d)))
head(cp$terms)
```

`prepare_documents` *Construye el conjunto de documentos y su auditoria*

Description

Aplica, en este orden, filtro por valor, filtro temporal, deduplicacion (DOI, titulo normalizado, texto normalizado) y muestreo con semilla. Los valores ausentes de anio o citas se conservan como `NA` (nunca como cero).

Usage

```
prepare_documents(d, mapping, config = default_config())
```

Arguments

`d`	`data.frame` de `read_biblio_csv()` o `read_biblio_file()`.
`mapping`	Lista de columnas, normalmente de `guess_columns()`.
`config`	Lista parcial de opciones; ver `default_config()`.

Value

Lista con `documents`, `audit`, `duplicates`, `issues`, `config` y `mapping`.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d))
p$audit
```

read_biblio_csv *Lee un CSV/TSV bibliografico con validaciones estrictas*

Description

Importa un archivo de texto sin aceptar lecturas parciales: rechaza archivos vacios, bytes nulos, filas con numero de campos inconsistente, encabezados duplicados o vacios y celdas de mas de 50 000 caracteres. Todas las columnas se leen como texto para conservar identificadores como `001`.

Usage

```
read_biblio_csv(path, sep = "auto", encoding = "UTF-8")
```

Arguments

`path`	Ruta del archivo.
`sep`	Separador: `"auto"`, `","`, `";"` o tabulador.
`encoding`	`"UTF-8"` o `"Latin-1"`.

Value

`data.frame` de caracteres con el atributo `source_md5`.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
dim(d)
```

read_biblio_file *Importa CSV, TSV, XLS o XLSX de una exportacion bibliografica*

Description

Detecta el formato por su firma binaria, no por la extension. En Excel lee la hoja indicada como texto y ajusta encabezados repetidos o vacios sin eliminar columnas (se registra en `import_info`).

Usage

```
read_biblio_file(
  path,
  name = basename(path),
  sep = "auto",
  encoding = "UTF-8",
  sheet = NULL
)
```

Arguments

path	Ruta del archivo.
name	Nombre original (para detectar extension en rutas temporales).
sep, encoding	Solo para texto; ver read_biblio_csv().
sheet	Hoja de Excel (por defecto la primera).

Value

data.frame de caracteres con atributos source_md5 e import_info (Excel).

Examples

```
f <- system.file("extdata", "practica.csv", package = "bibliolab")
d <- read_biblio_file(f, "practica.csv", sep = ";")
nrow(d)
```

---

reproducibility_record

Registro de reproducibilidad de una ejecucion

Description

Reune versiones de R y paquetes, plataforma, semillas, parametros y huella de los datos de entrada: lo necesario para repetir un analisis y para declararlo en la seccion de metodos.

Usage

```
reproducibility_record(
  prepared,
  corpus = NULL,
  lda = NULL,
  ca = NULL,
  density = NULL,
  network = NULL,
  comparison = NULL,
  pca = NULL,
  input_md5 = NULL
)
```

Arguments

prepared	Resultado de prepare_documents().
corpus	Resultado de prepare_corpus() (opcional).
lda, ca, pca, density, network, comparison	Resultados de los modelos, si existen.
input_md5	Huella MD5 del archivo importado, si se conoce.

Value

Lista serializable a JSON con software, entorno, semillas, datos y modelos.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d))
rec <- reproducibility_record(p)
rec$software$bibliolab
```

---

run_app *Lanza la aplicacion Bibliolab*

Description

Abre la interfaz guiada (Shiny) para importar un corpus bibliografico, prepararlo, explorar indicadores, ejecutar modelos exploratorios y exportar una entrega reproducible. Todo el calculo es local: no se envian datos a servicios externos.

Usage

```
run_app(
  launch.browser = interactive(),
  port = NULL,
  model_dir = NULL,
  max_upload_mb = 100
)
```

Arguments

launch.browser	Si se abre el navegador al iniciar. Por defecto, en sesiones interactivas.
port	Puerto TCP; NULL deja que Shiny elija uno libre.
model_dir	Carpeta donde se guardan los modelos UDPipe descargados (opcional). Por defecto tools::R_user_dir("bibliolab", "data").
max_upload_mb	Tamano maximo de archivo importado, en megabytes (entre 1 y 500; 100 por defecto).

Details

La aplicacion escucha exclusivamente en 127.0.0.1 (el propio equipo), incluso si la opcion global shiny.host indica otra direccion. No necesita aceptar conexiones entrantes desde otros equipos. Las descargas de modelos de idioma se realizan por una accion explicita del usuario. Antes de abrir, comprueba y carga los paquetes de todos los analisis. Si faltan paquetes de analisis, intenta instalarlos desde CRAN en una biblioteca del usuario (binarios en Windows). Si no completa la preparacion, no abre una interfaz con tecnicas pendientes. Esta comprobacion solo se ejecuta al llamar a run_app(), nunca al cargar el paquete.

Value

Se invoca por su efecto; devuelve invisible(NULL) al cerrar la app.

Examples

```
if (interactive()) {
  run_app()
}
```

run_ca *Analisis de correspondencias de terminos frecuentes*

Description

Analisis de correspondencias de terminos frecuentes

Usage

```
run_ca(corpus, max_terms = 60L, baseline = TRUE, B = 50L, seed = 2026L)
```

Arguments

corpus	Resultado de prepare_corpus().
max_terms	Terminos mas frecuentes incluidos (3-150).
baseline	Si se calcula una linea base por permutacion de la inercia por eje.
B	Permutaciones de la linea base.
seed	Semilla de la linea base.

Details

La linea base permuta, columna a columna, las unidades en las que aparece cada termino (se conservan los totales por termino). Un eje cuyo porcentaje de inercia no supera el percentil 95 de esa distribucion no se distingue de lo esperable por azar con esos totales.

Value

Lista con terms, units, dimensions (con umbral_azar_pct y supera_azar si baseline = TRUE), params y ran_at.

References

Greenacre, M. (2017). Correspondence Analysis in Practice (3rd ed.). CRC Press.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
cp <- prepare_corpus(prepare_documents(d, guess_columns(d)))
ca <- run_ca(cp, 30, B = 20)
ca$dimensions[1:3, ]
```

run_comparison *Compara dos grupos de documentos por su vocabulario*

Description

Compara periodos, categorias de metadatos, grupos de `run_density()` o temas dominantes de `run_lda()` mediante JSD, con matriz entre categorias, trayectoria por anios y, por defecto, referencia nula por permutacion e intervalo bootstrap (ver `jsd_uncertainty()`).

Usage

```
run_comparison(corpus, prepared, params = list(), grouping = NULL)
```

Arguments

corpus, prepared	Resultados de `prepare_corpus()` y `prepare_documents()`.
params	Lista parcial: `mode` (`"year"`, `"metadata"`, `"density"`, `"lda"`), `weighting` (`"tokens"` o `"documents"`), periodos o categorias, `uncertainty`, `B` y `seed`.
grouping	`data.frame` con `doc_id` y `valor` para modos distintos de `"year"`.

Value

Lista con `jsd`, `distancia`, `uncertainty`, `terms`, `matrix`, `coverage`, `temporal`, `audit`, `issues` y `params`.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d)); cp <- prepare_corpus(p)
yrs <- range(p$documents$year, na.rm = TRUE)
mid <- floor(mean(yrs))
fit <- run_comparison(cp, p, list(year_A_min = yrs[1], year_A_max = mid,
  year_B_min = mid + 1, year_B_max = yrs[2], B = 100))
fit$jsd
```

run_density *UMAP + HDBSCAN + c-TF-IDF*

Description

Representa los documentos (TF-IDF o BM25 + LSA, o vectores importados), reduce con UMAP, agrupa por densidad con HDBSCAN y describe los grupos con c-TF-IDF. Un solo resultado depende de la semilla y de los parametros: evalua su estabilidad con `density_sensitivity()`.

Usage

```
run_density(
  corpus,
  prepared,
  params = density_defaults(),
  vectors = NULL,
  embedding_model = "",
  display = TRUE
)
```

Arguments

corpus, prepared	Resultados de prepare_corpus() y prepare_documents().
params	Lista parcial de parametros (neighbors, cluster_dims, min_dist, min_pts, seed, epochs, lsa_dims, weighting, ...).
vectors	Vectores importados (ver read_document_vectors), opcional.
embedding_model	Nombre/version del modelo que genero los vectores.
display	Si se calcula tambien el UMAP 2D de lectura.

Value

Lista con assignments, summary, terms, examples, quality, similarity, temporal, params, representation e issues.

References

McInnes, L., Healy, J., Melville, J. (2018). UMAP. arXiv:1802.03426. Campello, R., Moulavi, D., Sander, J. (2013). Density-based clustering based on hierarchical density estimates. PAKDD.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d)); cp <- prepare_corpus(p)
if (all(c("uwot", "dbscan", "irlba") %in% rownames(utils::installed.packages()))) {
  fit <- run_density(cp, p, list(neighbors = 5L, min_pts = 3L))
  table(fit$assignments$grupo)
}
```

---

run_lda *Modelo LDA (Gibbs) con diagnosticos*

Description

Ajusta un LDA sobre los conteos de las unidades del corpus. A diferencia de V3, el prior de mezcla por documento alpha es explicito y por defecto 1/k (el valor de topicmodels, 50/k, produce mezclas casi uniformes en textos cortos). Devuelve ademas indicadores de calidad: coherencia, diversidad y convergencia aproximada de la log-verosimilitud.

Usage

```
run_lda(
  corpus,
  k = 4L,
  seed = 2026L,
  iterations = 500L,
  alpha = NULL,
  delta = 0.1,
  burnin = 100L,
  thin = 10L
)
```

Arguments

corpus	Resultado de prepare_corpus().
k	Numero de temas (2-12). Para elegirlo con apoyo, usa lda_select_k().
seed	Semilla (la ejecucion es reproducible con la misma semilla y corpus).
iterations	Iteraciones de Gibbs tras el burn-in (100-2000).
alpha	Prior de Dirichlet de los temas por documento; NULL usa 1/k.
delta	Prior de Dirichlet de las palabras por tema.
burnin, thin	Iteraciones descartadas y espaciado de las muestras.

Value

Lista con top, gamma, document_topics, prevalence, examples, diagnostics, loglik, params, units, terms y ran_at.

References

Blei, D., Ng, A., Jordan, M. (2003). Latent Dirichlet allocation. JMLR. Griffiths, T., Steyvers, M. (2004). Finding scientific topics. PNAS. Wallach, H., Mimno, D., McCallum, A. (2009). Rethinking LDA: why priors matter. NIPS.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
cp <- prepare_corpus(prepare_documents(d, guess_columns(d)))
if (requireNamespace("topicmodels", quietly = TRUE)) {
  fit <- run_lda(cp, k = 3, iterations = 200)
  fit$diagnostics$overview
}
```

---

run_network *Redes bibliometricas y lexicas*

Description

Construye una red no dirigida de coautoria, copresencia de palabras, afinidad lexica de revistas, cocitacion de referencias o acoplamiento bibliografico, y calcula indicadores del grafo filtrado: densidad, componentes, centralidades, comunidades (Louvain o Walktrap) y su estabilidad entre semillas.

Usage

```
run_network(corpus, prepared, params = list())
```

Arguments

corpus, prepared	Resultados de `prepare_corpus()` y `prepare_documents()`.
params	Lista parcial: `type`, `weighting` (`"full"`, `"fractional"`, `"cosine"`, `"association"`), `min_presence`, `max_nodes`, `min_shared`, `seed`, `community_method`, `resolution`, `max_edges`, `keyplayers_k`, `remove_isolates` (retira aislados tras filtrar conexiones) e `include_nodes` (nombres prioritarios que superan el umbral; conserva el maximo de nodos).

Value

Lista con `nodes`, `edges`, `summary`, `audit`, `selection` (cada entidad y su motivo de inclusion/exclusion), `keyplayers`, `note` y `params`.

References

Blondel, V. et al. (2008). Fast unfolding of communities in large networks. J. Stat. Mech. van Eck, N. J., Waltman, L. (2009). How to normalize cooccurrence data? JASIST.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d)); cp <- prepare_corpus(p)
net <- run_network(cp, p, list(type = "words", max_nodes = 15))
net$summary
```

---

run_pca *Analisis de componentes principales sobre perfiles TF-IDF*

Description

Analisis de componentes principales sobre perfiles TF-IDF

Usage

```
run_pca(
  corpus,
  prepared,
  max_terms = 100L,
  standardize = FALSE,
  baseline = TRUE,
  B = 50L,
  seed = 2026L
)
```

Arguments

corpus, prepared	Resultados de prepare_corpus() y prepare_documents().
max_terms	Terminos mas frecuentes incluidos (3-300).
standardize	Si se estandarizan los terminos a varianza 1.
baseline, B, seed	Linea base por permutacion de la varianza por componente (percentil 95), numero de permutaciones y semilla.

Value

Lista con documents, terms, dimensions, params y excluded.

References

Jolliffe, I. T. (2002). Principal Component Analysis (2nd ed.). Springer.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d)); cp <- prepare_corpus(p)
run_pca(cp, p, 30, B = 20)$dimensions[1:3, ]
```

---

vocabulary_diagnostics

Diagnostico del vocabulario retenido

Description

Ayuda a decidir umbrales y palabras vacias propias del corpus: muestra como cambia el vocabulario al variar la presencia minima, que terminos aparecen en una gran parte de los documentos (candidatos a palabras vacias propias del corpus, que decide el investigador) y que documentos quedan con muy pocas palabras. No modifica el corpus.

Usage

```
vocabulary_diagnostics(corpus, prepared, generic_pct = 25, min_terms = 5L)
```

Arguments

corpus	Resultado de prepare_corpus().
prepared	Resultado de prepare_documents().
generic_pct	Porcentaje de documentos desde el cual un termino se marca como candidato generico.
min_terms	Documentos con menos de este numero de terminos retenidos se cuentan como pobres.

Value

Lista con sensitivity, generic, coverage, suggestion y boilerplate.

Examples

```
d <- read_biblio_csv(system.file("extdata", "practica.csv", package = "bibliolab"), ";")
p <- prepare_documents(d, guess_columns(d))
vocabulary_diagnostics(prepare_corpus(p), p)$sensitivity
```

Index

biblio_check_dependencies, 3
biblio_summary, 3
biblio_summary(), *11*

default_config, 4
default_config(), *13*
density_sensitivity, 4
density_sensitivity(), *6*, *11*, *18*
download_language_model, 5

export_bundle, 6
extract_subgraph, 7

guess_columns, 7
guess_columns(), *13*

jsd_shift, 8
jsd_uncertainty, 8
jsd_uncertainty(), *8*, *18*

lda_select_k, 9
lda_select_k(), *6*, *11*, *20*

methods_report, 10
methods_report(), *12*
methods_report_html, 11
model_directory, 12
model_directory(), *5*

prepare_corpus, 12
prepare_corpus(), *4, 5*, *10, 11*, *15*, *17–22*
prepare_documents, 13
prepare_documents(), *3–5*, *11, 12*, *15*, *18, 19*, *21, 22*

read_biblio_csv, 14
read_biblio_csv(), *13*, *15*
read_biblio_file, 14
read_biblio_file(), *13*
reproducibility_record, 15
reproducibility_record(), *11*
run_app, 16
run_ca, 17
run_comparison, 18
run_density, 18
run_density(), *5*, *18*
run_lda, 19
run_lda(), *18*
run_network, 20
run_network(), *7*
run_pca, 21

vocabulary_diagnostics, 22